Classification supervisée

Fiche TP1

W. Heyse

Contents

1 Analyse préliminaire du jeu de données iris **1**

2 Analyse factorielle discriminante **2**

2.1 Calcul des matrices de variance-covariance 2

2.2 Réalisation de l'AFD 2

2.3 Calcul des scores discriminants 3

1 Analyse préliminaire du jeu de données iris

Dans cette partie on utilisera les données iris. Faire `data("iris")` dans `R`.

1. Renommer les variables `Sepal.Length`, `Sepal.Width`, `Petal.Length`, `Petal.Width`, `Species` en `X1`, `X2`, `X3`, `X4`, `Y`.
2. Représenter graphiquement le lien entre `X1` et `Y`. Faire de même pour les autres variables.

On pourra utiliser : `plot(X1~Y,data=iris)`, `ggplot(aes(x = Y, y = X1, fill = Y), data = iris) + geom_boxplot()` ou même

```
library(ggplot2)
library(tidyr)
library(dplyr)
iris %>%
  gather("variable","mesure",-Y) %>%
  ggplot(aes(x = Y, y = mesure, col = Y)) +
  geom_boxplot() +
  facet_wrap(~ variable, scales = "free_y")
```

3. En utilisant la fonction `pairs` avec l'option `col`, représenter graphiquement les liens entre couples de variables quantitatives et le groupe.

On pourra aussi utiliser la fonction `ggpairs` du package `GGally`

4. Réaliser l'ANOVA de `X1` en fonction de `Y` et obtenir le R^2 associé, faire de même pour les autres variables. A partir des p-values, indiquer si la variable `Y` a une influence sur l'ensemble des variables. Quelle est la variable la mieux expliquée par `Y` ?

Afin d'automatiser les calculs, on pourra utiliser le code suivant :

```
allanov<-lapply(1:4,FUN=function(i){
  anova(lm(get(paste0("X",i))~Y,data=iris))
  })
allpval<-sapply(allanov,FUN=function(x) x$`Pr(>F)`[1])
#sapply équivaut ici à unlist(lapply())
```

```
allpval
allr2<-sapply(summary(lm(cbind(X1,X2,X3,X4)~Y,data=iris)),
              FUN=function(x) x$r.squared)
allr2
```

2 Analyse factorielle discriminante

2.1 Calcul des matrices de variance-covariance

1. Calculer V la matrice de variance-covariance globale, à partir de la fonction `cov.wt` en utilisant l'option `method = "ML"`. Expliquer à quoi sert cette option. Attention on prendra garde de récupérer le bon élément de sortie de la fonction `cov.wt`, fonction qui ressort une liste contenant entre autres `cov`, `center`, ...

Remarque : si vous voulez interpréter les dépendances 2 à 2, il faut calculer la matrice des corrélations, option `cor = TRUE`.

2. Calculer les matrices W_i, $i = 1, \ldots, 3$, de covariance intra-groupe, de la même façon que précédemment, mais en sélectionnant à chaque fois les individus nécessaires au calcul de la covariance.

En déduire W à l'aide la formule :

$$W = \frac{n_1 W_1 + n_2 W_2 + n_3 W_3}{n}$$

Remarque : On peut utiliser la commande `by` pour automatiser le calcul des matrices de variance-covariance intra-groupe. Les effectifs par groupe s'obtiennent via la commande `table`.

3. Calcul de la matrice de variance-covariance inter-groupes B.

- Calculer les vecteurs des moyennes pour chaque groupe $\bar{X}_i$ (vous pourrez éventuellement vous aider de la fonction by). Puis constituez la matrice G de centres des classes constituée d'une colonne par variable et d'une ligne par sous-espèce.
- En déduire :

$$B = \sum_{i=1}^{K} \frac{n_i}{n} (\bar{X}_i - \bar{X})(\bar{X}_i - \bar{X})'$$

  où $\bar{X}_i$, $\bar{X}$ sont respectivement les vecteurs colonnes des moyennes intra-classes et de la moyenne globale. Pour cela on pourra remarquer que B est la matrice de covariance des centres des classes pondérés par leurs effectifs (penser à `cov.wt` et à son argument `wt`).

4. Vérifier numériquement qu'on retrouve bien : $V = W + B$.

2.2 Réalisation de l'AFD

On rappelle que dans `R` l'ACP peut se réaliser à la main comme suit :

```
ACP=eigen(V)$vectors
c=as.matrix(iris[,1:4])%*%ACP[,1:2]
plot(c,col=iris$Y)
```

1. Quel est le pourcentage d'inertie expliqué par chacun des axes? Par les deux premiers axes?
2. Adapter le code pour réaliser l'AFD, sachant qu'en AFD, on diagonalise la matrice $V^{-1}B$ (on rappelle que l'inverse s'obtient avec la fonction `solve` et le produit matriciel avec l'opérateur `\%*\%`). Calculer les coordonnées d_1 et d_2 des points projetés sur les deux premières composantes discriminantes.
3. Quelle est la part de variance de d_1 expliquée par la classe ? De d_2?

4. Reprendre le code précédent en remplaçant $V^{-1}B$ par $W^{-1}B$. Démontrer que l'on a la relation : $\mu_j = \dfrac{\lambda_j}{1-\lambda_j}$ avec λ_j les valeurs propres de $V^{-1}B$ et μ_j celles de $W^{-1}B$.
5. Comparer les résultats obtenus à ceux obtenus en ACP.

2.3 Calcul des scores discriminants

1. Calculer les fonctions de score pour chacun des groupes, ces fonctions nous serviront ensuite à affecter chaque individu au groupe de plus grand score (équivalent à la minimisation de la distance de Mahalanobis).

On rappelle que le calcul des fonctions de score pour chaque groupe s'effectue comme suit :

$$s_i(x) = \alpha_{i0} + \alpha_{i1}x_1 + \alpha_{i2}x_2 + \alpha_{i3}x_3 + \alpha_{i4}x_4$$

avec $\alpha_{i0} = -\bar{X}_i' W^{-1} \bar{X}_i$ et

$$\begin{pmatrix} \alpha_{i1} \\ \vdots \\ \alpha_{ip} \end{pmatrix} = 2W^{-1}\bar{X}_i$$

Construire le tableau des coefficients:

	Setosa	Versicolor	Virginica
α_0	α_{10}	α_{20}	α_{30}
$X_1 : \alpha_1$	α_{11}	α_{21}	α_{31}
$X_2 : \alpha_2$	α_{12}	α_{22}	α_{32}
$X_3 : \alpha_3$	α_{13}	α_{23}	α_{33}
$X_4 : \alpha_4$	α_{14}	α_{24}	α_{34}

Rappel : Dans l'AFD, la notion de score est liée au calcul de la règle de décision. Une observation $x = (x_1, x_2, \ldots, x_p)$ sera affectée au groupe avec le score $s_i(x)$ maximal.\ Rappel:

$$\hat{y} = \arg\min_i (x - \bar{X}_i)' W^{-1} (x - \bar{X}_i)$$

Ce calcul revient à maximiser $2x'W^{-1}\bar{X}_i - \bar{X}_i' W^{-1} \bar{X}_i$.

2. Calculer les scores des individus à partir de cette règle (simple calcul matriciel, on pourra rajouter une colonne de 1 à la matrice des données à l'aide de la fonction `cbind`) .
3. En déduire le classement de chacun des individus à partir de ces scores (en utilisant de façon appropriée les fonctions `apply` et `which.max`).