

ISia4 – BDN – T.P. 3

© Polytech Lille

Résumé

Ce TP aborde l'utilisation MongoDB/Python.

N'hésitez pas à consulter la documentation en ligne sur le site de MongoDB : <https://docs.mongodb.com/v4.2/reference/> (car la version installée est la 4.2 de MongoDB).

Initialisation du TP

1. Pour ce TP, nous allons utiliser la même base de données `tp` que pour le TP1.
2. Remettez-vous dans votre dossier racine de votre TP1.
3. lancer le daemon dans un shell

```
mongod --dbpath data/db/ &
```

Attention, n'oubliez pas de remettre le lien vers MongoDB dans la variable `$PATH` avant d'utiliser les outils de MongoDB :

(1)

```
export PATH=$PATH:/usr/localTP/mongo/bin
```

(Si à chaque TP vous lancez les même commandes pour étendre le `$PATH`, vous pouvez ajouter la commande (1) directement à la fin du fichier `.bashrc` qui se trouve dans votre répertoire home (taper `kate ~/.bashrc` pour y accéder)).

4. Accéder à la base de données à l'aide d'un script python :
 - Écrire dans un fichier externe `nomFichier.py`
 - Charger le fichier à l'aide de

```
python3 nomFichier.py
```

I Pour bien commencer le TP

L'objectif de ce TP est l'utilisation de MongoDB à l'aide de python. Nous allons utiliser le package `pymongo` pour nous connecter à la base de données MongoDB qui vous avez lancé en local :

- I.1. Importez la classe `MongoClient` du package `pymongo`

```
1 from pymongo import MongoClient
```

- I.2. Instanciez un objet `client` qui va se connecter à vos bases de données, à l'aide de la classe `MongoClient`

```
2 client = MongoClient(host="localhost", port=numero_du_port)
```

où `numero_du_port` est le numéro du port sur lequel s'est connecté votre daemon de MongoDB.

- I.3. Sélectionnez la base de données `tp`

```
3 db = client[db_name]
```

où `db_name` est le nom de votre base de données

I.4. Sauvegardez vos résultats de requêtes dans un objet de type range

```
4 cursor = db.restaurants.aggregate([...])
```

I.5. Utiliser vos données en les transformant en une liste de résultats : la variable `cursor` est un objet range, c'est une sorte de liste qui se vide d'un élément dès l'utilisation de celui-ci. Pour éviter cet effet, on sauvegarde les valeurs de `cursor` dans la liste `l_resultat`

```
5 l_resultat = list(cursor)
```

En résumé, pour vous connectez à la base de données `tp` :

```
1 from pymongo import MongoClient
2 client = MongoClient(host="localhost", port=27017)
3 db = client["tp"]
4 cursor = db.restaurants.aggregate([...])
5 l_resultat = list(cursor)
```

II Prise en main avec Python

II.1. Affichez l'ensemble du document du restaurant "30075445" (attribut "restaurant_id")

II.2. Bon ok, c'est un peu moche ...

Importez le package `pprint` et utilisez la méthode `pprint.pprint()` au lieu de `print()` pour améliorer la visualisation de votre document/dictionnaire.

Dans le futur, vous utiliserez `pprint.pprint()` pour visualiser un dictionnaire ou une liste de dictionnaires et `print()` pour les autres variables.

II.3. Récupérez le nom du restaurant et affichez-le de la manière suivante :

```
Le nom du restaurant est "Morris Park Bake Shop"
```

II.4. Récupérez la liste des grades du restaurant et affichez-les de la manière suivante (vous pourrez utiliser la méthode `.strftime('%d/%m/%Y')` des objets `datetime`) :

```
Le grade A a été mis le 03/03/2014
Le grade A a été mis le 11/09/2013
Le grade A a été mis le 24/01/2013
Le grade A a été mis le 23/11/2011
Le grade B a été mis le 10/03/2011
```

II.5. Récupérez en une nouvelle requête, la liste des 5 premiers restaurants classés par cuisine et affichez-les de la manière suivante :

```
Le restaurant "Afghan Kebab House" fait de la cuisine "Afghan"
Le restaurant "Afghan Kebab House #1" fait de la cuisine "Afghan"
Le restaurant "Afghan Kebab House" fait de la cuisine "Afghan"
Le restaurant "Ariana Kebab House" fait de la cuisine "Afghan"
Le restaurant "Arya Kabob House" fait de la cuisine "Afghan"
```

III Évolution des scores

III.1. Créez une requête `mongodb` qui permet de ne garder que les documents correspondant à la date et au score des grades du restaurant 30075445. La sortie devrait être de la forme suivante :

```
[{'date': datetime.datetime(2014, 3, 3, 0, 0), 'score': 2},
 {'date': datetime.datetime(2013, 9, 11, 0, 0), 'score': 6},
 {'date': datetime.datetime(2013, 1, 24, 0, 0), 'score': 10},
 {'date': datetime.datetime(2011, 11, 23, 0, 0), 'score': 9},
 {'date': datetime.datetime(2011, 3, 10, 0, 0), 'score': 14}]
```

III.2. Stockez la date de grades dans une liste et le score correspondant dans une autre liste.

III.3. Afficher l'évolution des scores des grades en fonction du temps.

Indice : vous utiliserez le package `matplotlib` de python pour afficher vos graphiques.

- Importez le package `matplotlib`
`import matplotlib.pyplot as plt`
- Construisez le graphique pour deux listes `x` et `y` de même taille :
`plt.plot(x,y)`
- Affichez le graphique :
`plt.show()`

III.4. On voudrait afficher cette évolution pour tous les restaurants qui ont un nombre maximum de grades et qui sont français (French). Commencez par trouver une requête mongo qui renvoie le plus grand nombre de grades des restaurants qui sont français.

III.5. Faites une deuxième requête mongo en utilisant ce nombre de grades maximum de restaurant français pour calculer liste des documents qui sont de cuisine française de nombre maximum de grades. Vous devriez trouver ce type de documents en sortie :

```
[{'cuisine': 'French',
  'grades': [{'date': datetime.datetime(2015, 1, 17, 0, 0), 'grade': 'A', 'score': 12},
             {'date': datetime.datetime(2014, 1, 8, 0, 0), 'grade': 'A', 'score': 11},
             {'date': datetime.datetime(2013, 7, 30, 0, 0), 'grade': 'C', 'score': 48},
             {'date': datetime.datetime(2012, 11, 15, 0, 0), 'grade': 'B', 'score': 25},
             {'date': datetime.datetime(2012, 6, 8, 0, 0), 'grade': 'A', 'score': 12},
             {'date': datetime.datetime(2012, 5, 24, 0, 0), 'grade': 'P', 'score': 14},
             {'date': datetime.datetime(2012, 1, 18, 0, 0), 'grade': 'A', 'score': 10}],
  'name': 'Cafe Un Deux Trois'},
 ...]
```

III.6. (bonus) La combinaison des requêtes de III.4 et III.5 a permis de trouver la liste des documents qui sont de cuisine française de nombre maximum de grades. Proposez une unique requête mongo pour trouver cette même liste.

III.7. Afficher l'évolution des scores des grades en fonction du temps pour l'ensemble des restaurants de votre dernière requête mongo et ajouter une légende avec le nom des restaurants sur le graphique.

IV Proportion par quartier pour un type de cuisine

IV.1. Créez une requête qui affiche par quartier (borough), le nombre de restaurant à sandwich (Sandwiches).

IV.2. Affichez le résultat précédent sous forme de camembert (`plt.pie(...)`). Si vous voulez, vous pouvez utiliser les options `labels` et `autopct`.

IV.3. Calculer pour chaque type de cuisine, le pourcentage de ce type de cuisine à Brooklyn par rapport à l'ensemble des quartiers.

Exemples :

- si un type de restaurant n'est qu'à Brooklyn, alors son pourcentage sera de 100.
- si la moitié des restaurants est à Brooklyn, alors son pourcentage sera de 50.

On pourra commencer par calculer la liste des types de cuisines à l'aide d'une requête mongo et ensuite pour chaque type de cuisine, calculer le nombre total de restaurant de ce type par quartier. Il ne restera plus qu'à calculer le pourcentage en regardant le nombre de restaurant de Brooklyn de ce quartier sur le nombre de restaurant total de ce quartier.

- IV.4. (*bonus*) La combinaison des requêtes de IV.3 a permis de calculer pour chaque type de cuisine, le pourcentage de ce type de cuisine à Brooklyn par rapport à l'ensemble des quartiers. Proposez une unique requête mongo pour trouver cette même liste.
- IV.5. Afficher ces résultats sous forme de bar vertical (`plt.barh(...)`). On pourra trier les éléments par pourcentage décroissant pour une meilleur lisibilité.